A. รวมหลักการและวิธีการ

ในภาคผนวกนี้ได้รวบรวมหลักการและวิธีการที่สนับสนุนเนื้อหาหลักของหนังสือ

```
import numpy as np
import matplotlib.pyplot as plt
import tensorflow as tf
from tensorflow import keras
```

A.1 ค่าเฉลี่ยที่ให้น้ำหนักแบบเลขชี้กำลัง

ในการปรับปรุงตัวหาค่าเหมาะที่สุดในบทที่ 3 มีการอ้างอิงถึง *ค่าเฉลี่ยให้น้ำหนักแบบเลขชี้กำลัง (exponentially weighted averages)* ต่อไปจะใช้ตัวย่อ EWA ซึ่งมีการใช้ในงานสาขาสถิติ เพื่อช่วยในการลดทอนการแกว่งของข้อมูล คือทำหน้าที่คล้ายตัวกรองความถี่ต่ำในวงจรไฟฟ้า บางครั้งจะเรียกชื่อเต็มว่า *ค่าเฉลี่ยเคลื่อนที่ให้น้ำหนักแบบเลขชี้กำลัง (exponentially weighted moving average)* เพราะการหาค่าเฉลี่ยจะมีการเคลื่อนที่เป็นหน้าต่างที่มีขนาดเท่ากับจำนวนจุดข้อมูล เราจะละคำว่า “เคลื่อนที่” ออกเพื่อความกระชับ

ตัวอย่าง A.1

เพื่อความเป็นรูปธรรมในการสาธิตจะใช้ข้อมูลสังเคราะห์ 140 จุด ที่ผสมผสานระหว่างแนวโน้ม (trend) กับการรบกวน สร้างเวกเตอร์ $k, y(k)$ ได้โดยฟังก์ชัน `gen_data()` ดังนี้

```
def gen_data():
    t_vec = np.arange(-0.7,0.7,0.01)
    t_vec = t_vec[:,np.newaxis]
    numpts = t_vec.shape[0]
    y_vec = 1.5*t_vec**3 - t_vec + 0.7/(3 + 40*t_vec**2)
                        + 0.3*np.random.rand(numpts,1)
    k_vec = np.arange(0,numpts)
    k_vec = k_vec[:,np.newaxis]
    return k_vec, y_vec
```

```
k_vec, y_vec = gen_data()
```

พล็อตข้อมูลดังแสดงในรูปที่ A.1

```
plt.figure()
plt.plot(k_vec,y_vec,'bo')
plt.xlabel("t")
plt.ylabel("y(k)")
plt.show()
```

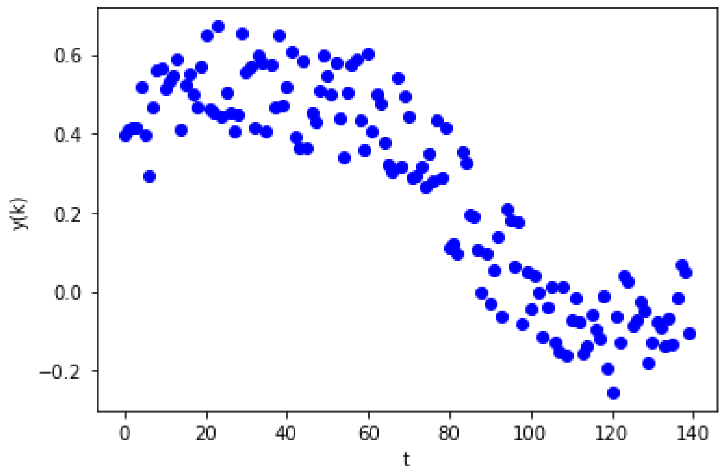

รูปที่ A.1 ข้อมูลสังเคราะห์สำหรับการสาธิต EWA

จะเห็นว่าข้อมูลมีการรบกวนค่อนข้างมาก วิธีการ EWA ทำได้โดยกำหนดตัวแปร $v_k, \quad k = 0, 1, \ldots$ ที่เริ่มต้นจากศูนย์

$$v_0 = 0 \quad (A.1)$$

และค่าที่ตัวชี้ต่อไปเป็นไปตามสมการ

$$v_k = \beta v_{k-1} + (1-\beta)y_k \quad (A.2)$$

พิจารณาโดยประมาณได้ว่า v_k คือการเฉลี่ยค่าจำนวน $1/(1-\beta)$ จุดข้อมูล ตัวอย่างเช่น $\beta = 0.5, 0.9, 0.98$ คือการเฉลี่ยค่าทุก 2,10,50 จุดข้อมูลตามลำดับ

จากสมการ (A.1), (A.2) สามารถเขียนเป็นฟังก์ชัน `ewa()` ได้ดังนี้

```
def ewa(y, beta):
    v_size = y.shape[0]
    v = np.zeros((v_size,1))
    for k in range(1,v_size):
        v[k,0] = beta*v[k-1,0] + (1-beta)*y[k,0]
    return v
```

ทดลองรันฟังก์ชันกับข้อมูลสังเคราะห์ในรูปที่ A.1 โดยใช้ค่า $\beta = 0.5, 0.9, 0.98$ ได้ผลดังรูปที่ A.2

```
v_1 = ewa(y_vec,0.5)
v_2 = ewa(y_vec,0.9)
v_3 = ewa(y_vec,0.98)
plt.figure()
plt.plot(k_vec,y_vec,'bo',k_vec,v_1,'r-
',k_vec,v_2,'g-.',k_vec,v_3,'m:')
plt.xlabel("t")
plt.ylabel("y(k),v(k)")
plt.legend(["original
data","beta=0.5","beta=0.9","beta=0.98"])
plt.show()
```

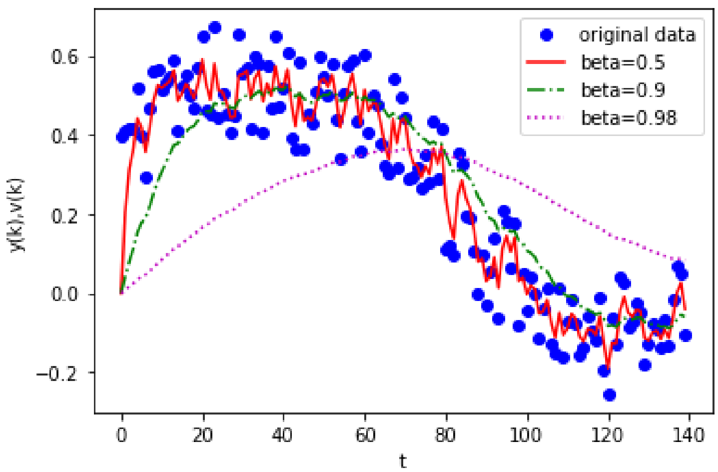

รูปที่ A.2 ผลจากการรันฟังก์ชัน ewa() โดยใช้ค่า $\beta = 0.5, 0.9, 0.98$

จากผลในรูปที่ A.2 จะเห็นได้ว่าเมื่อเพิ่มค่าของ β คือการหาค่าเฉลี่ยโดยใช้หน้าต่างที่มีจำนวนจุดมากขึ้น การรบกวนจะลดลง แต่ผลเสียคือกราฟจะเลื่อนมาทางด้านขวาเหมือนมีการหน่วงเวลา

A.1.1 การแก้ไขค่าเอนเอียง

หากพิจารณาผลของการใช้ EWA ในรูปที่ A.1 ในช่วงเริ่มต้นของกราฟจะเห็นว่ามีค่าน้อยกว่าข้อมูลจริง ทั้งนี้เนื่องจากเรากำหนดค่าของ $v_0 = 0$ *การแก้ไขค่าเอนเอียง (bias correction)* ทำได้โดยหลังจากคำนวณค่า v_k ตาม (A.2) ปรับมาตราส่วนค่าของ v_k ดังนี้

$$\tilde{v}_k = \frac{v_k}{1 - \beta^k} \quad \text{(A.3)}$$

จะเห็นได้ว่าพจน์ของส่วนด้านขวาของ (A.3) คือ $1 - \beta^k$ มีค่าน้อยในช่วงเริ่มต้นของขั้นตอนวิธี ช่วยให้ v_k ถูกชดเชยให้มีค่ามากขึ้น หลังจาก k มีค่าสูงขึ้น $1 - \beta^k$ ลู่เข้าสู่ 1 คือการชดเชยจะน้อยลงตามลำดับ

หมายเหตุ : ประเด็นสำคัญที่สามารถทำให้การคำนวณได้ค่าไม่ถูกต้องคือ ต้องใช้ค่าของ v_k ใน (A.2) (ที่ยังไม่ได้ถูกชดเชย) เป็น v_{k-1} ในรอบต่อไป

ในการใช้งานด้านการเรียนรู้ของเครื่อง การแก้ค่าเอนเอียงอาจไม่มีผลมากนักในการปรับปรุงขั้นตอนวิธีหาค่าเหมาะที่สุด ยกเว้นการใช้ในบางส่วนของขั้นตอนวิธีที่กล่าวถึงในบทที่ 3

ตัวอย่าง A.2

แก้ไขฟังก์ชัน `ewa()` เป็น `ewa_bc()` โดยเพิ่มการปรับมาตราส่วน (A.3) ผลของการแก้ค่าเอนเอียงกับข้อมูลเดิมจากตัวอย่าง A.1 เป็นดังรูปที่ A.3

```
def ewa_bc(y, beta):
    v_size = y.shape[0]
    v = np.zeros((v_size,1))
    v_tmp=0
    for k in range(1,v_size):
        v_tmp = beta*v_tmp + (1-beta)*y[k,0]
        v[k,0] = v_tmp/(1-beta**k)
    return v
```

```
v_1_bc = ewa_bc(y_vec,0.5)
v_2_bc = ewa_bc(y_vec,0.9)
v_3_bc = ewa_bc(y_vec,0.98)
plt.figure()
plt.plot(k_vec,y_vec,'bo',k_vec,v_1_bc,'r-',
         k_vec,v_2_bc,'g-.',k_vec,v_3_bc,'m:')
plt.xlabel("t")
plt.ylabel("y(k),v(k)")
plt.legend(["original
data","beta=0.5","beta=0.9","beta=0.98"])
plt.show()
```

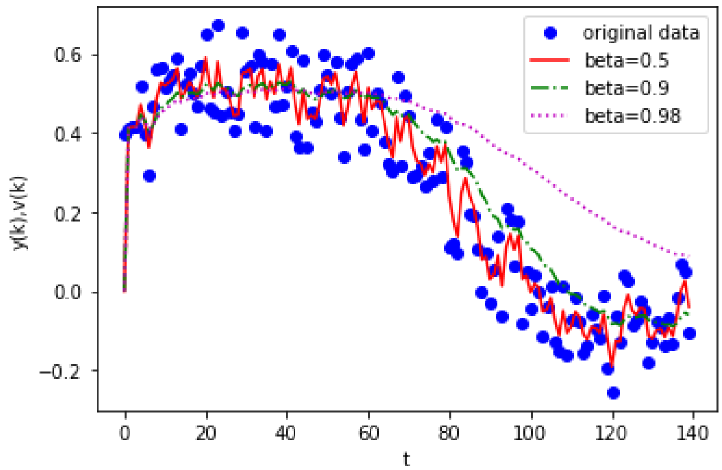

รูปที่ A.3 ผลจากการรันฟังก์ชัน ewa_bc() ที่มีการแก้ไขค่าเอนเอียง

A.2 ข้อมูลอนุกรมเวลา

โมเดลข้อมูลลำดับในบทที่ 5 สามารถใช้พยากรณ์ *ข้อมูลอนุกรมเวลา (time series data)* ตัวอย่างเช่นในรูปที่ A.4 เป็นอนุกรมเวลาของจำนวนไมล์ต่อเดือนที่รถยนต์ทั้งหมดเดินทางในประเทศสหรัฐอเมริกา เก็บในช่วงเวลา ค.ศ. 2000 - 2014 เป็นเวลา 15 ปี [BV18]

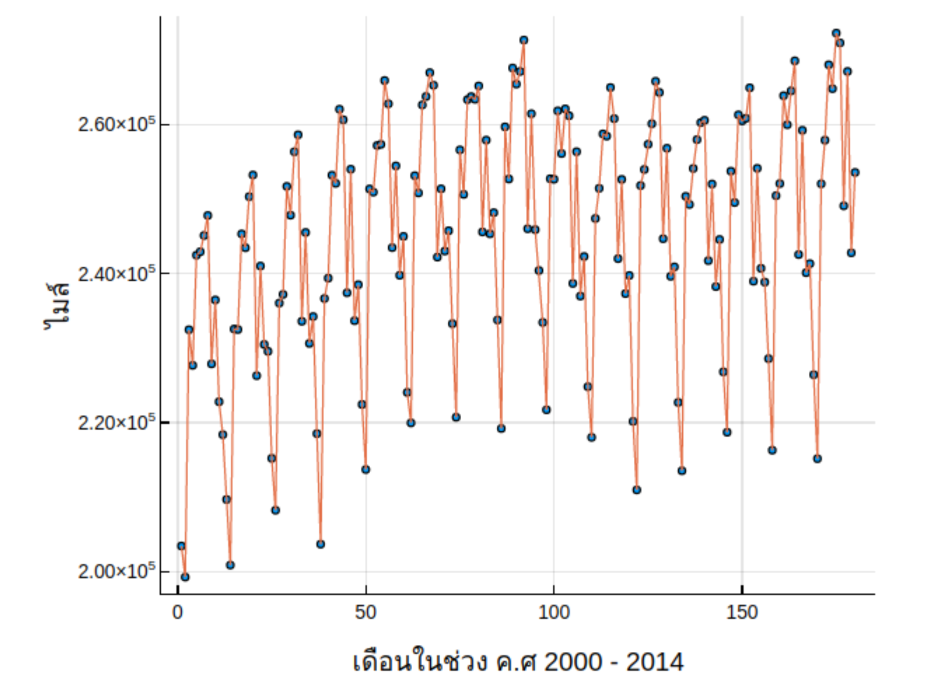

รูปที่ A.4 จำนวนไมล์ต่อเดือนที่รถทั้งหมดในสหรัฐอเมริกาเดินทางในปี ค.ศ. 2000 - 2014

ข้อมูลอนุกรมเวลาโดยทั่วไปเป็นผลรวมองค์ประกอบหลักดังนี้

- แนวโน้ม (trend)
- ตามฤดูกาล (seasonal)
- การรบกวน (noise)
- สหสัมพันธ์อัตโนมัติ (autocorrelation)

โดยอาจมีองค์ประกอบเพียงบางตัวหรือทั้งหมดก็ได้ เนื้อหาในส่วนนี้จะเป็นการศึกษาพื้นฐานของอนุกรมเวลา โดยใช้ข้อมูลสังเคราะห์ซึ่งดัดแปลงจากที่ใช้สาธิตในวิชา “Sequence, Time Series and Prediction” โดย Laurence Moroney [Mor20] ไลบรารีที่ใช้คือ `numpy` และ `matplotlib` ที่นำเข้าในส่วนต้นของภาคผนวกนี้

นิยามฟังก์ชันสำหรับพล็อตอนุกรม

```
def plot_series(time, series, format="-", start=0,
end=None, label=None,xlabel="time
(days)",ylabel="value"):
    plt.plot(time[start:end], series[start:end], format,
label=label)
    plt.xlabel(xlabel)
    plt.ylabel(ylabel)
    if label:
        plt.legend(fontsize=14)
    plt.grid(True)
```

A.2.1 แนวโน้ม

แนวโน้มในข้อมูลคือแบบอย่างที่เป็นตัวบอกว่าค่าในระยะยาวเพิ่มขึ้นหรือลดลง ตัวอย่างเช่นจำนวนประชากรในกรุงเทพมหานครมีแนวโน้มมากขึ้น แนวโน้มจะแทนโดยกราฟเส้นตรงที่มีความชันเป็นตัวกำหนดการเพิ่มขึ้น/ลดลง/คงที่ นิยามฟังก์ชัน `trend()` สำหรับใช้ในการสร้างข้อมูลสังเคราะห์ดังนี้

```
def trend(t, slope=0):
    return slope * t
```

ทดลองสร้างข้อมูลรายวันในช่วงเวลา 4 ปี มีแนวโน้มที่มีความชัน -0.2 ดังแสดงในรูปที่ A.5 ผู้อ่านสามารถเปลี่ยนความชันตามต้องการ

```
time = np.arange(4 * 365 + 1)
y_trend = trend(time, -0.2)
plot_series(time, y_trend)
```

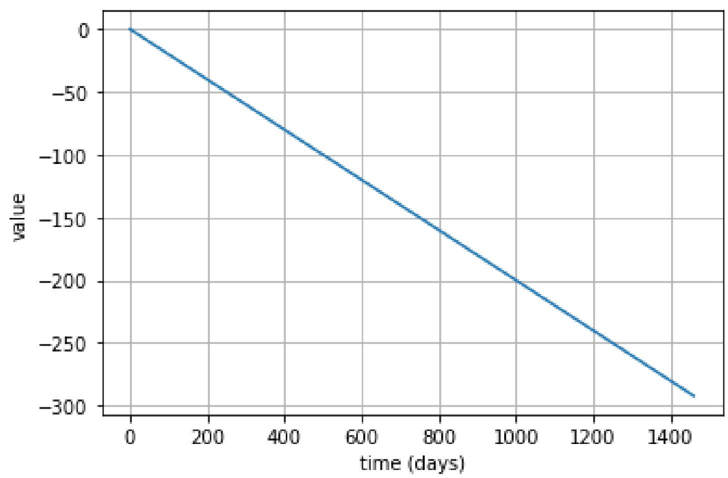

รูปที่ A.5 กราฟเส้นตรงแทนแนวโน้มข้อมูลที่สร้างโดยฟังก์ชัน trend()

A.2.2 องค์ประกอบตามฤดูกาล

องค์ประกอบตามฤดูกาลได้ชื่อเรียกมาจากลักษณะข้อมูลที่มีแบบรูปเหมือนกันในแต่ละฤดูของปี เช่นการท่องเที่ยวทางภาคใต้ของประเทศไทยซบเซาลงในช่วงฤดูฝน แต่สำหรับด้านวิทยาการข้อมูล นิยามนี้ครอบคลุมถึงองค์ประกอบที่มีลักษณะเป็นรายคาบโดยไม่คำนึงถึงหน่วยในแกนเวลา เช่นอุณหภูมิที่ลดต่ำในช่วงกลางคืนถึงเช้าและเพิ่มสูงในช่วงบ่ายก็สามารถจัดได้เป็นองค์ประกอบตามฤดูกาล หรือแม้แต่สัญญาณจากการสั่นสะเทือนของเครื่องจักรกลแบบหมุนที่ขาดสมดุลย์ที่มีคาบเวลาหน่วยมิลลิวินาที

ข้อมูลสังเคราะห์ที่ใช้ในหนังสือได้มาจากการนิยามฟังก์ชัน `seasonality()` ที่เรียกใช้ `seasonal_pattern()` โดยภายในฟังก์ชันนี้สร้างแบบรูปตามฤดูกาลขึ้นตามที่เราต้องการ

```
def seasonal_pattern(season_time):
    return np.where(season_time < 0.4,
                    -np.cos(season_time * 2.8 * np.pi),
                    -0.1*np.exp(2.3*season_time))

def seasonality(time, period, amplitude=1, phase=0):
    season_time = ((time + phase) % period) / period
    return amplitude * seasonal_pattern(season_time)
```

ทดลองสร้างข้อมูลตามฤดูกาลรายปีที่มี `amplitude=50` ดังในรูปที่ A.6

```
series = seasonality(time, period=365,
                     amplitude=50)
plot_series(time, series)
```

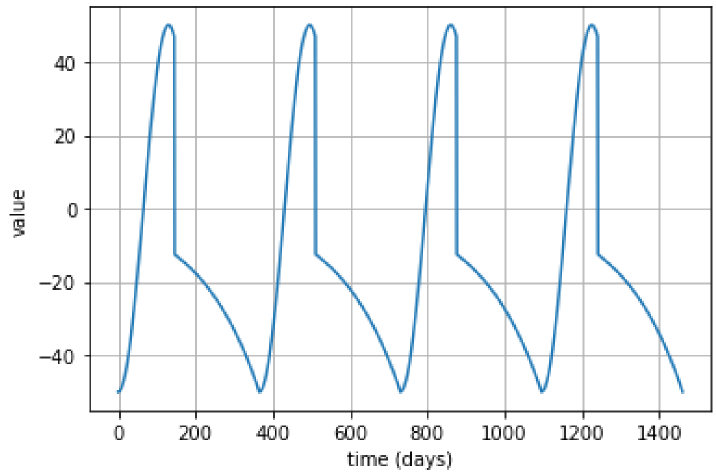

รูปที่ A.6 องค์ประกอบตามฤดูกาลสร้างโดยฟังก์ชัน seasonality()

เมื่อรวมแนวโน้มกับองค์ประกอบตามฤดูกาลเข้าด้วยกัน โดยให้ค่าเริ่มต้นเท่ากับ 50 ความชัน 0.04 ได้ดังรูปที่ A.7

```
baseline = 50
series = baseline + trend(time, 0.04) + seasonality(
                    time, period=365, amplitude=50)
plot_series(time, series)
```

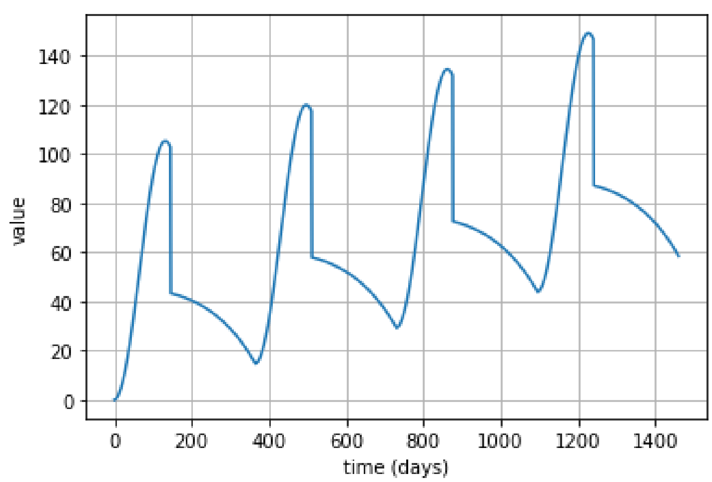

รูปที่ A.7 กราฟจากการรวมแนวโน้มและองค์ประกอบตามฤดูกาล

A.2.3 การรบกวน

โดยทั่วไปการรบกวนที่เกิดขึ้นในการวัดหรือจัดเก็บข้อมูลจะถูกโมเดลเป็นค่าสุ่ม เช่น *สัญญาณรบกวนสีขาว (white noise)* นิยามฟังก์ชัน `noise()` สำหรับกำเนิดการรบกวนได้ดังนี้

```
def noise(time, noise_level=1):
    return np.random.randn(len(time)) * noise_level
```

พล็อตการรบกวนที่กำเนิดจากฟังก์ชัน `noise()` ได้ดังรูปที่ A.8

```
plot_series(time,noise(time, noise_level=10))
```

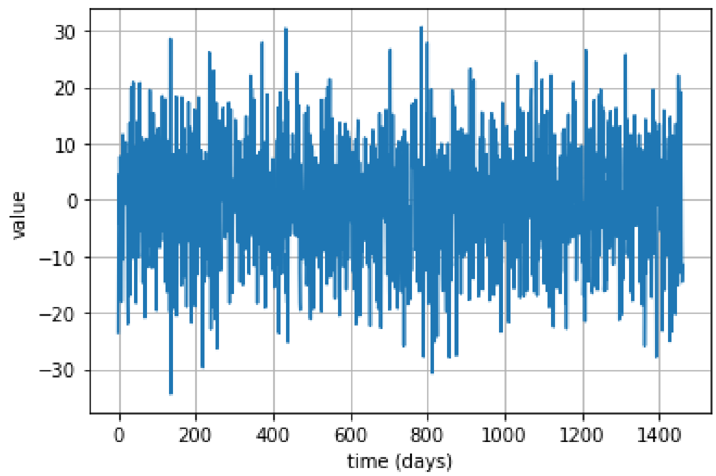

รูปที่ A.8 การรบกวนที่สร้างโดยฟังก์ชัน noise()

เมื่อเพิ่มการรบกวนให้กับกราฟในรูปที่ A.7 จะได้เป็นดังรูปที่ A.9

```
noise_level = 15
noisy_series = series + noise(time, noise_level)
sample_time = time  # to be used later on
plot_series(time, noisy_series)
```

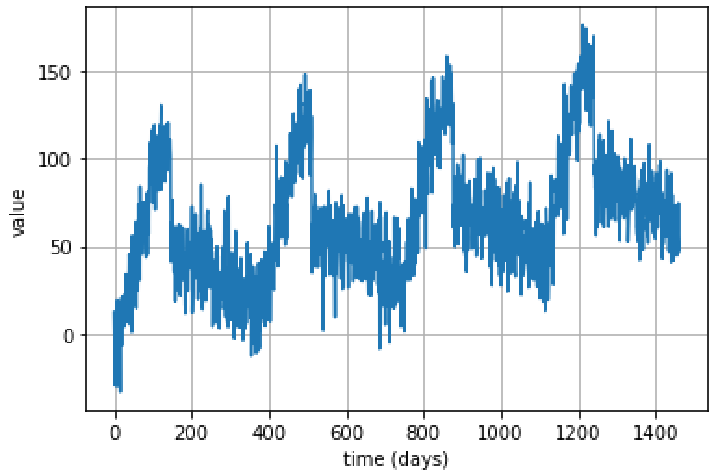

รูปที่ A.9 ข้อมูลสังเคราะห์ที่เพิ่มการรบกวน

A.2.4 สหสัมพันธ์อัตโนมัติ

องค์ประกอบอีกรูปแบบหนึ่งที่อาจพบได้ในข้อมูลเรียกว่า *สหสัมพันธ์อัตโนมัติ (autocorrelation)* ดังตัวอย่างในรูปที่ A.10 เป็นผลรวมของอิมพัลส์ที่เกิดขึ้นแบบสุ่ม กับสหสัมพันธ์อัตโนมัติ $v(t) = 0.99v(t-1)$ ซึ่งเป็นค่าเชิงกำหนด (deterministic)

```
def impulses(time, num_impulses, amplitude=1,
seed=None):
    rnd = np.random.RandomState(seed)
    impulse_indices = rnd.randint(len(time), size=10)
    series = np.zeros(len(time))
    for index in impulse_indices:
        series[index] += rnd.rand() * amplitude
    return series
```

```
def autocorrelation(source, φs):
    ar = source.copy()
    max_lag = len(φs)
    for step, value in enumerate(source):
        for lag, φ in φs.items():
            if step - lag > 0:
              ar[step] += φ * ar[step - lag]
    return ar
```

```
signal = impulses(time, 10, seed=42)
series = autocorrelation(signal, {1: 0.99})
plot_series(time, series,xlabel="time")
plt.plot(time,signal, "k-")
plt.show()
```

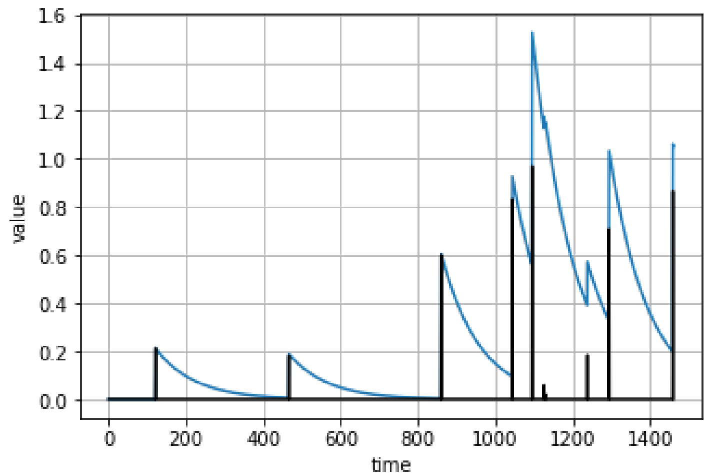

รูปที่ A.10 ข้อมูลอนุกรมเวลาที่เป็นผลรวมของอิมพัลส์กับสหสัมพันธ์อัตโนมัติ

ตัวอย่างเพิ่มเติมของข้อมูลสหสัมพันธ์อัตโนมัติแสดงได้ดังในรูปที่ A.11 และ A.12

```
def autocorrelation1(time, amplitude):
    rho1 = 0.7
    rho2 = -0.3
    ar = np.random.randn(len(time) + 50)
    ar[:50] = 100
    for step in range(50, len(time) + 50):
        ar[step] += rho1 * ar[step - 50]
        ar[step] += rho2 * ar[step - 33]
    return ar[50:] * amplitude
```

```
series = autocorrelation1(time, 20)
plot_series(time[:200], series[:200],xlabel="time")
```

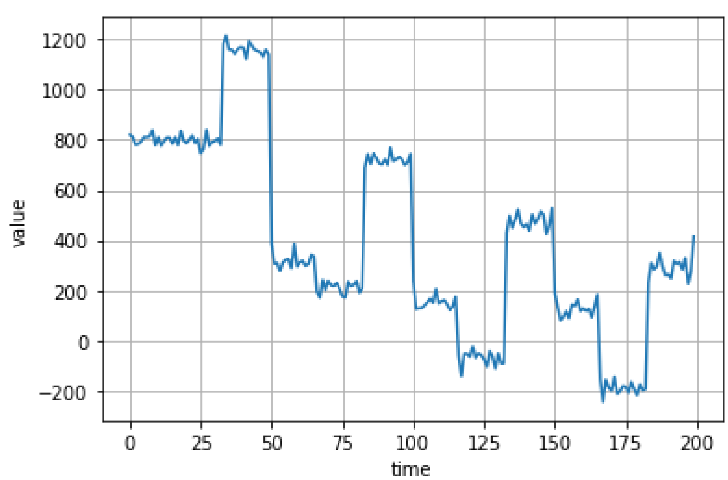

รูปที่ A.11 ตัวอย่างข้อมูลสหสัมพันธ์อัตโนมัติ

```python
def autocorrelation2(time, amplitude):
    rho = 0.6
    ar = np.random.randn(len(time) + 1)
    for step in range(1, len(time) + 1):
        ar[step] += rho * ar[step - 1]
    return ar[1:] * amplitude
```

```python
series = autocorrelation2(time, 20)
plot_series(time[:200], series[:200], xlabel="time")
```

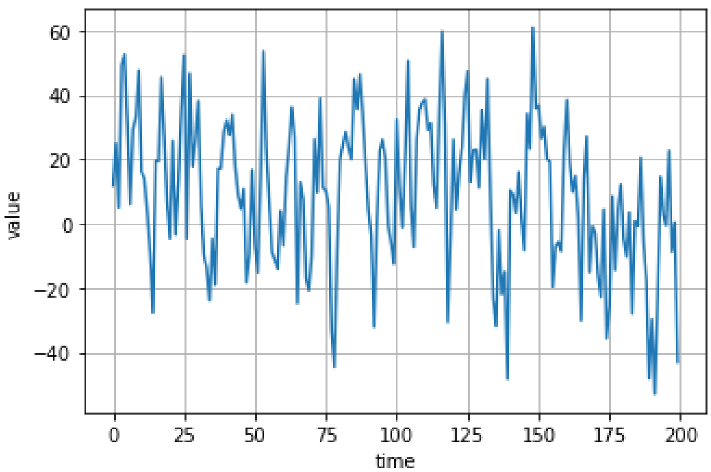

รูปที่ A.12 ตัวอย่างข้อมูลสหสัมพันธ์อัตโนมัติ

รูปที่ A.13 แสดงตัวอย่างข้อมูลที่เป็นการผสมผสานแนวโน้ม องค์ประกอบเชิงฤดูกาล และสหสัมพันธ์อัตโนมัติ

```python
series = autocorrelation2(time, 10) + seasonality(time,
            period=50, amplitude=150) + trend(time, 2)
plot_series(time[:200], series[:200],xlabel="time")
```

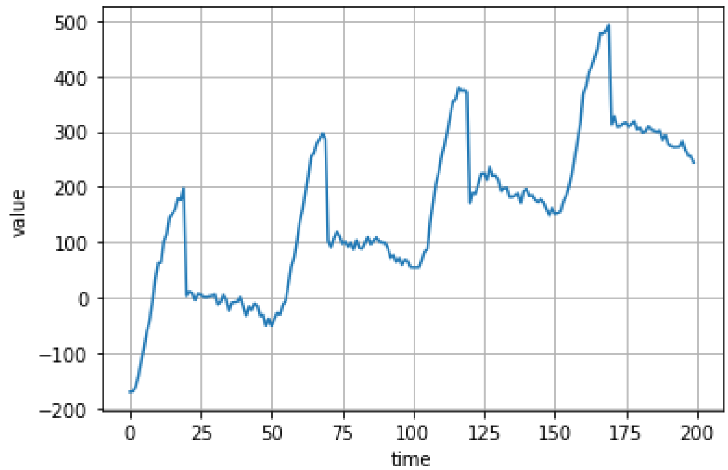

รูปที่ A.13 ข้อมูลแนวโน้ม+องค์ประกอบตามฤดูกาล+สหสัมพันธ์อัตโนมัติ

A.2.5 อนุกรมเวลาไม่คงที่

ในกรณีที่ข้อมูลมีรูปแบบแน่นอนจนกระทั่งถึงจุดหนึ่งที่มีการเปลี่ยนแปลงรูปแบบไป เรียกว่า *อนุกรมเวลาไม่คงที่ (non-stationary)* สาเหตุอาจเกิดจากมีเหตุการสำคัญที่ส่งผลกระทบอย่างรุนแรง ตัวอย่างเช่นข้อมูลจำนวนนักท่องเที่ยวทางภาคใต้ในทุกปีจะมากในช่วงฤดูร้อนและน้อยในฤดูฝน แต่เมื่อมีการระบาดหนักของโควิด-19 จำนวนนักท่องเที่ยวลดลงเหลือน้อยมากตลอดปี

รูปที่ A.14 แสดงตัวอย่างอนุกรมเวลาไม่คงที่จากข้อมูลสังเคราะห์ที่มีการเปลี่ยนแปลงแบบรูป ณ เวลา $t = 180$ ในการเลือกข้อมูลเพื่อฝึกโมเดลจะต้องพิจารณาในส่วนนี้ เพราะโดยทั่วไปเรามักยึดติดกับแนวคิดว่ายิ่งมีข้อมูลฝึกมากยิ่งดี แต่ในกรณีนี้การเลือกข้อมูลฝึกหลังจาก $t = 180$ จะให้ผลดีกว่า

```
series = autocorrelation2(time, 10) + seasonality(time,
period=50, amplitude=150) + trend(time, 2)
series2 = autocorrelation2(time, 5) + seasonality(time,
period=50, amplitude=2) + trend(time, -1) + 500
series[180:] = series2[180:]
plot_series(time[:300], series[:300],xlabel="time")
```

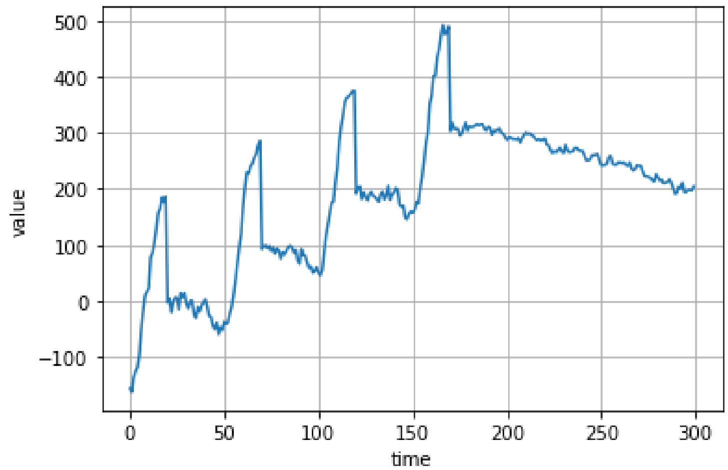

รูปที่ A.14 ตัวอย่างอนุกรมเวลาไม่คงที่

A.3 การพยากรณ์ข้อมูลอนุกรมเวลา

ข้อมูลอนุกรมเวลาที่เราประสบในชีวิตจริงอาจประกอบด้วยลักษณะเด่น 4 รูปแบบดังที่ได้กล่าวมาข้างต้น วัตถุประสงค์หลักคือสามารถตรวจจับรูปแบบเหล่านี้เพื่อพยากรณ์ค่าในอนาคตได้ (ยกเว้นส่วนของการรบกวนที่ไม่สามารถคาดเดาได้)

ในการเลือกข้อมูลสำหรับฝึกและทดสอบ หากข้อมูลมีองค์ประกอบตามฤดูกาล ควรแบ่งส่วนให้แต่ละส่วนครอบคลุมจำนวนเต็มของคาบเวลา ตัวอย่างเช่นแบบรูปตามฤดูกาลเป็นรายปี ให้เลือกข้อมูลฝึกเป็นจำนวนเต็มของปี เช่น 3 ปี ไม่ควรเลือก 1.5 ปี เพราะจะทำให้บางส่วนของข้อมูลรายคาบถูกใช้ในการฝึกมากกว่าส่วนอื่น

รูปที่ A.15 แสดง *การแบ่งส่วนคงที่ (fixed partitioning)* สำหรับตัวอย่างข้อมูลในรูปที่ A.9 เป็นข้อมูลฝึก ตรวจสอบ และทดสอบ

อีกวิธีการหนึ่งที่นิยมใช้ในการแบ่งข้อมูลแสดงในรูปที่ A.16 คือแบ่งข้อมูลทั้งหมดที่มีอยู่สำหรับการฝึกและตรวจสอบ ส่วนการทดสอบย้ายไปยังเวลาในอนาคต

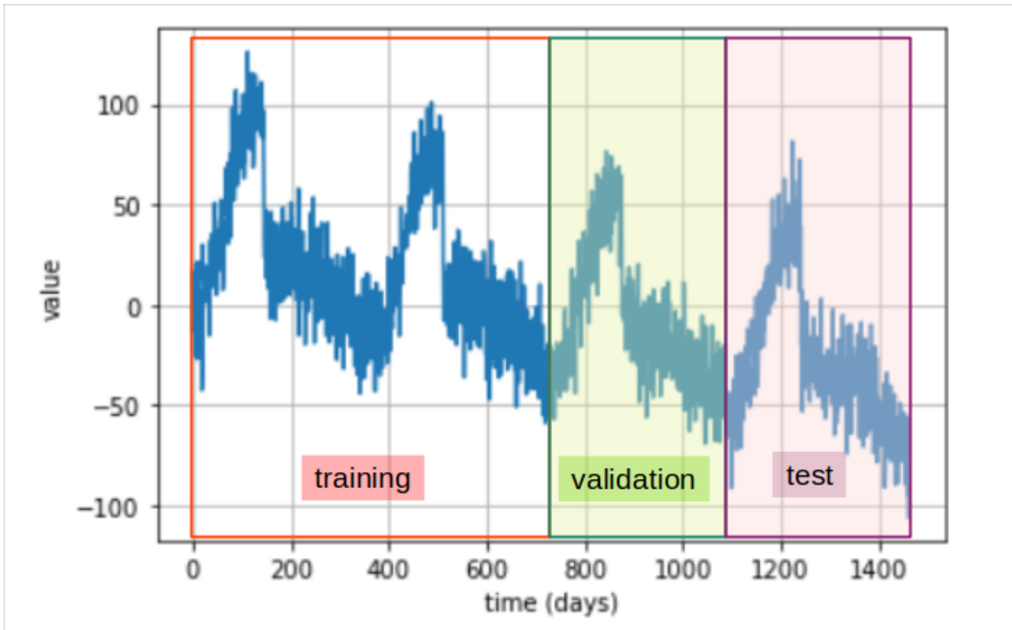

รูปที่ A.15 ตัวอย่างการแบ่งส่วนคงที่สำหรับข้อมูลฝึก ตรวจสอบ และทดสอบ

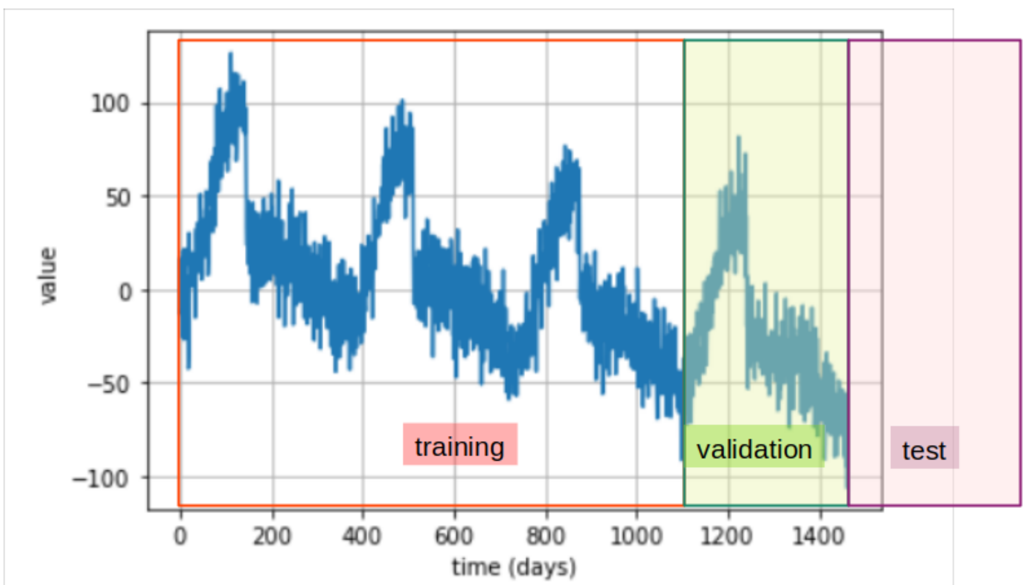

รูปที่ A.16 อีกวิธีการหนึ่งในการแบ่งส่วนข้อมูลสำหรับฝึก ตรวจสอบ และทดสอบ

A.3.1 ตัววัดสมรรถนะ

ในการศึกษาว่าโมเดลสามารถพยากรณ์ได้ดีเพียงใด เราต้องการตรวจสอบค่าความผิดพลาดในการพยากรณ์ (ซึ่งก็ไม่แตกต่างจากค่าสูญเสียของโมเดลถดถอยเชิงเส้นในบทที่ 2) พิจารณาค่าผิดพลาด

$$e(t) = y(t) - \hat{y}(t) \quad (\text{A.4})$$

โดย $y(t)$ และ $\hat{y}(t)$ คือค่าจริงและค่าที่พยากรณ์ตามลำดับ จะเห็นว่าค่าผิดพลาด (A.4) อาจมีค่าเป็นบวกและลบในแต่ละขั้นเวลา ดังนั้นเมื่อรวมเข้าด้วยกันอาจหักล้างกัน ทำให้มีค่ารวมน้อยลง ซึ่งไม่ใช่สิ่งที่เราต้องการ ดังนั้นจะต้องมีการแปลงให้เป็นค่าบวกทั้งหมดโดยการยกกำลังสองหรือใช้ค่าสัมบูรณ์ กำหนดตัวแปร `errors` เป็นเวกเตอร์เก็บค่าผิดพลาดของข้อมูลตาม (A.4) ในช่วงเวลาที่ต้องการ ตัววัดที่นิยมใช้มีดังนี้

```
mse = np.square(errors).mean()
rmse = np.sqrt(mse)
mae = np.abs(errors).mean()
mape = np.abs(errors/x_valid).mean()
```

โดย `mse` (mean square error), `rmse` (root mean square error), `mae` (mean absolute error), `mape` (mean absolute percentage error) ทั้งหมดมีค่าเป็นบวกที่เป็นดัชนีของความแม่นยำในการพยากรณ์ สังเกตว่า `mse`, `rmse` จะใช้วิธียกกำลังสองค่าผิดพลาด ดังนั้นค่าผิดพลาดที่มีค่าสูงจะถูกให้น้ำหนักมากกว่า หากไม่ใช่สิ่งที่ต้องการควรเลือกใช้ `mae` หรือ `mape` (`x_valid` คือค่าของอินพุต)

เราสามารถเลือกใช้ตัววัดที่ต้องการได้จากไลบรารี `keras` ได้ ตัวอย่างเช่น `mse` และ `mae` ใช้คำสั่งดังนี้

```
keras.metrics.mean_squared_error(x_valid, naive_forecast).numpy()
keras.metrics.mean_absolute_error(x_valid,
naive_forecast).numpy()
```

A.3.2 เส้นฐานการพยากรณ์

หากเราต้องการวิเคราะห์ว่าการพยากรณ์โดยโมเดลการเรียนรู้เชิงลึกได้ผลดีมากน้อยเพียงใด จำเป็นต้องมีค่าวัดที่เป็นเส้นฐาน (baseline) โดยเราจะใช้วิธีการแบบง่ายสุด คือ ให้ค่าการพยากรณ์เท่ากับค่าสุดท้ายของข้อมูล ทดลองใช้กับข้อมูลที่มีการรบกวนในรูปที่ A.9 (ซึ่งต่อไปจะใช้ข้อมูลจาก `sample_series` และ `sample_time` นี้เป็นตัวอย่างประกอบเนื้อหา)

แบ่งส่วนข้อมูลสำหรับฝึกและตรวจสอบที่เวลา $t = 1095$ คือใช้ข้อมูล 3 ปีสำหรับฝึกและ 1 ปีสำหรับตรวจสอบ รูปที่ A.17 และ A.18 แสดงอนุกรมเวลาที่แยกเป็นข้อมูลฝึกและทดสอบตามลำดับ

```
sample_series = noisy_series
split_time = 365*3
```

```
time_train = sample_time[:split_time]
x_train = sample_series[:split_time]
```

```
time_valid = sample_time[split_time:]
x_valid = sample_series[split_time:]
```

```
plt.figure(figsize=(8,5))
plot_series(time_train, x_train)
plt.show()
```

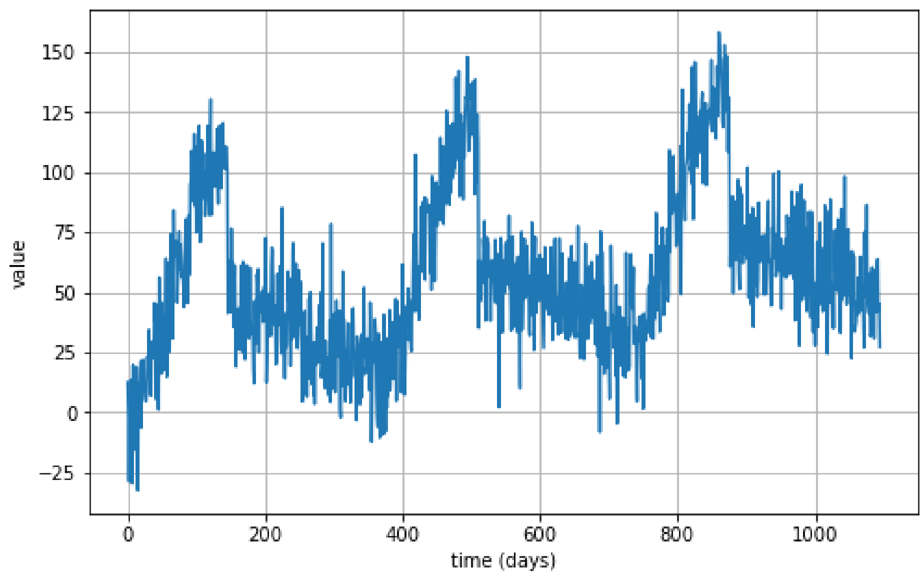

รูปที่ A.17 ข้อมูลสำหรับการฝึก

```
plt.figure(figsize=(8, 5))
plot_series(time_valid, x_valid)
plt.show()
```

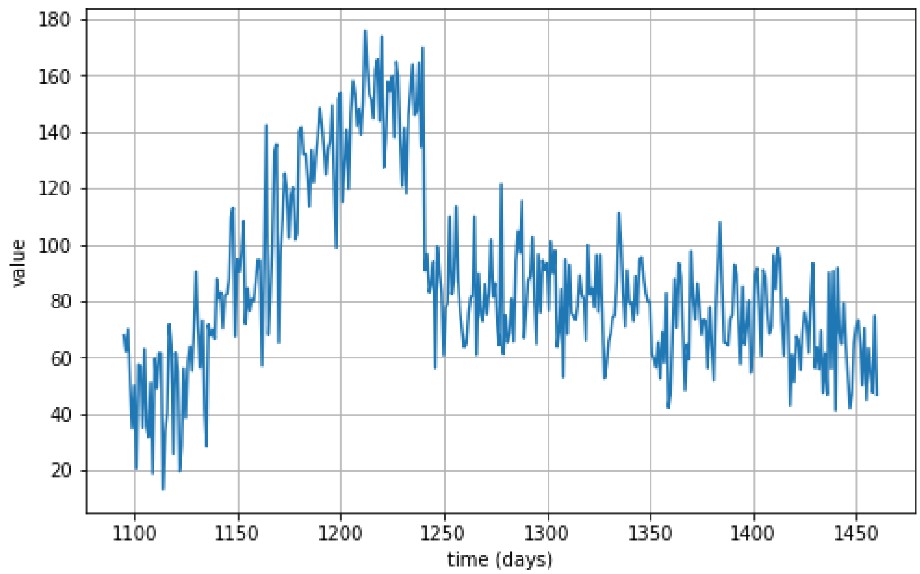

รูปที่ A.18 ข้อมูลสำหรับตรวจสอบ

การพยากรณ์อย่างง่ายให้ผลเป็นดังรูปที่ A.19

```
naive_forecast = sample_series[split_time - 1:-1]
plt.figure(figsize=(8, 5))
plot_series(time_valid, x_valid)
plot_series(time_valid, naive_forecast)
```

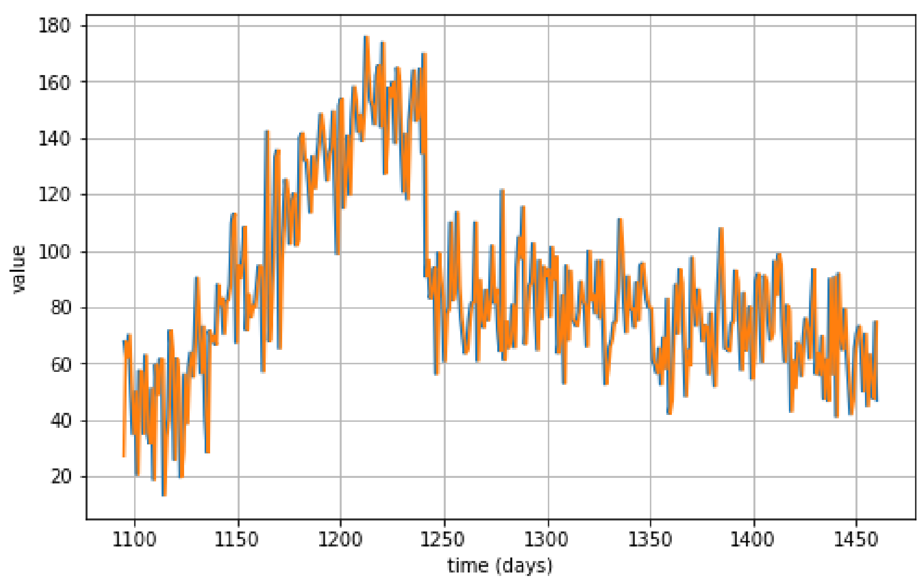

รูปที่ A.19 ผลจากการพยากรณ์อย่างง่าย

ซึ่งดูเหมือนเป็นการพยากรณ์ที่ดี แต่หากขยายกราฟดังในรูปที่ A.20 จะเห็นว่ากราฟการพยากรณ์ล้าหลังข้อมูลจริงอยู่ 1 วัน

```
plt.figure(figsize=(8, 5))
plot_series(time_valid, x_valid, start=0, end=150)
plot_series(time_valid, naive_forecast, start=1,
                                        end=151)
```

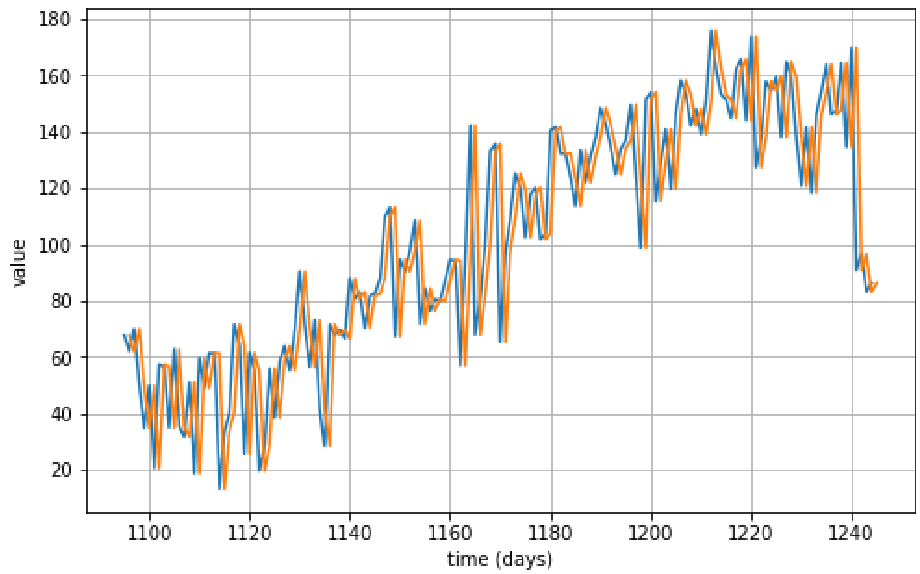

รูปที่ A.20 ผลจากการพยากรณ์อย่างง่ายเมื่อขยายแกนเวลา

ตรวจสอบค่าตัววัด `mse` และ `mae` ที่เราจะใช้เป็นค่าเส้นฐาน

```
print(keras.metrics.mean_squared_error(x_valid,
                        naive_forecast).numpy())
print(keras.metrics.mean_absolute_error(x_valid,
                        naive_forecast).numpy())
```

```
434.3780304104924
16.27624466936418
```

A.3.3 การจัดรูปข้อมูลอนุกรมเวลา

ในการพยากรณ์โดยโมเดลเรียนรู้เชิงลึก เราต้องจัดข้อมูลให้อยู่ในรูปแบบของการเรียนรู้โดยมีผู้สอนที่ได้ศึกษาในหนังสือนี้ โดยประกอบด้วยอินพุต X ที่ป้อนให้กับโมเดลเพื่อพยากรณ์ $\hat{y}$ เปรียบเทียบกับข้อมูลจริงคือเลเบล y วิธีการที่ใช้คือสร้างหน้าต่างของเวลาดังรูปที่ A.21 โดยกำหนดจำนวนจุดเวลาในหน้าต่างเช่น 30 วัน หรือตามที่ต้องการ ข้อมูลในหน้าต่างยกเว้นค่าสุดท้ายคืออินพุต X ของโมเดล และข้อมูลค่าสุดท้ายคือเลเบล y กวาดหน้าต่างนี้ตั้งแต่เริ่มต้นของอนุกรมเวลาไปยังจุดสิ้นสุดของข้อมูลที่แบ่งสำหรับการฝึก

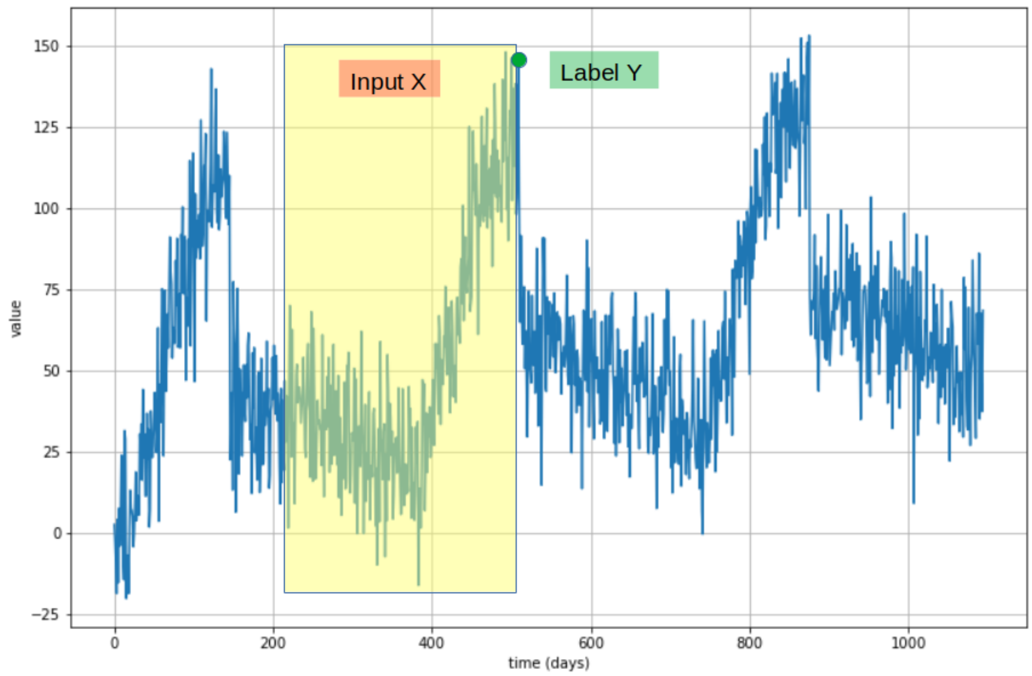

รูปที่ A.21 การจัดรูปอนุกรมเวลาสำหรับการเรียนรู้เชิงลึก

ก่อนที่จะดำเนินการกับข้อมูลอนุกรมเวลาสังเคราะห์ เพื่อให้เข้าใจถึงหลักการและโค้ดที่ใช้ จะสาธิตวิธีการจัดรูปโดยใช้ค่าตัวเลขที่กำเนิดขึ้นอย่างง่ายคือ 0-9

```
dataset = tf.data.Dataset.range(10)
```

ทดลองจัดรูปโดยใช้หน้าต่างขนาด 5 และเลื่อนหน้าต่างครั้งละ 1 ขั้นเวลา หลังจากนั้นตัดส่วนตัวเลขที่ไม่ครบ 5 ทิ้งไปโดยกำหนด `drop_remainder=True`

```
dataset = dataset.window(5, shift=1,
                         drop_remainder=True)
dataset = dataset.flat_map(lambda window:
                           window.batch(5))
for window in dataset:
    print(window.numpy())
```

```
[0 1 2 3 4]
[1 2 3 4 5]
[2 3 4 5 6]
[3 4 5 6 7]
[4 5 6 7 8]
[5 6 7 8 9]
```

สร้างส่วนของเลเบลเป็นตัวเลขที่ถัดจากค่าสุดท้ายของหน้าต่าง

```
dataset = dataset.map(lambda window: (window[:-1],
                                      window[-1:]))
for x,y in dataset:
    print(x.numpy(), y.numpy())
```

```
[0 1 2 3] [4]
[1 2 3 4] [5]
[2 3 4 5] [6]
[3 4 5 6] [7]
[4 5 6 7] [8]
[5 6 7 8] [9]
```

ใช้เมธอด `dataset.shuffle()` เพื่อสลับข้อมูล

```
dataset = dataset.shuffle(buffer_size=10)
for x,y in dataset:
    print(x.numpy(), y.numpy())
```

```
[2 3 4 5] [6]
[5 6 7 8] [9]
[0 1 2 3] [4]
[3 4 5 6] [7]
[4 5 6 7] [8]
[1 2 3 4] [5]
```

ต่อมาคือการจัดกลุ่มย่อยโดยเลือกเท่ากับ 2

```
dataset = dataset.batch(2).prefetch(1)
for x,y in dataset:
    print("x = ", x.numpy())
    print("y = ", y.numpy())
```

```
x =  [[5 6 7 8]
 [4 5 6 7]]
y =  [[9]
 [8]]
x =  [[2 3 4 5]
 [1 2 3 4]]
y =  [[6]
 [5]]
x =  [[3 4 5 6]
 [0 1 2 3]]
y =  [[7]
 [4]]
```

ตัวอย่าง A.3

ในขั้นแรกจะทดลองพยากรณ์โดยโมเดลชั้นเดี่ยว หรือโมเดลถดถอยเชิงเส้นในบทที่ 2 และเปรียบเทียบตัววัดค่าผิดพลาดกับค่าเส้นฐาน ใช้วิธีการจัดรูปข้อมูลที่สาธิตก่อนหน้านี้กับข้อมูลในรูปที่ A.17, A.18 โดยเลือกขนาดหน้าต่างเท่ากับ 20 ข้อมูลที่ใช้อยู่ในตัวแปร `x_train`, `x_valid`, `time_train`, `time_valid` จากด้านบน

```
window_size = 20
batch_size = 32
shuffle_buffer_size = 1000
```

```
def windowed_dataset(series, window_size, batch_size,
                                               shuffle_buffer):
  dataset = tf.data.Dataset.from_tensor_slices(series)
  dataset = dataset.window(window_size + 1, shift=1,
                              drop_remainder=True)
  dataset = dataset.flat_map(lambda window:
                      window.batch(window_size + 1))
  dataset = dataset.shuffle(shuffle_buffer).map(
          lambda window: (window[:-1], window[-1]))
  dataset = dataset.batch(batch_size).prefetch(1)
  return dataset
```

```
train_dataset = windowed_dataset(x_train, window_size,
                    batch_size, shuffle_buffer_size)
```

สร้างชั้นของโมเดลที่มีขนาดอินพุตเท่ากับขนาดหน้าต่าง และเอาต์พุตค่าเดียว

```
l0 = tf.keras.layers.Dense(1, input_shape=[window_size])
model = tf.keras.models.Sequential([l0])
```

คอมไพล์โมเดลโดยเลือกค่าสูญเสียแบบ mse และตัวหาค่าเหมาะที่สุดตามต้องการ ในตัวอย่างนี้เลือกเป็นแบบ `SGD()` ที่มีการใช้โมเมนตัม

```
model.compile(loss="mse", optimizer=
              tf.keras.optimizers.SGD(
              learning_rate=1e-6, momentum=0.9))
```

ฝึกโมเดลเป็นจำนวน 100 รอบ

```
model.fit(train_dataset,epochs=100,verbose=0)
```

ตรวจสอบค่าพารามิเตอร์จากการเรียนรู้หลังการฝึกเสร็จสิ้น

```
print("Layer weights {}".format(l0.get_weights()))
```

```
Layer weights [array([[-0.03568586],
       [ 0.01343471],
       [-0.03823332],
       [-0.00935871],
       [-0.00287514],
       [-0.01209861],
       [-0.01534943],
       [ 0.02018438],
       [ 0.04501085],
       [-0.03893059],
       [ 0.01673399],
       [ 0.0753949 ],
       [ 0.13711569],
       [ 0.07956365],
       [ 0.03806845],
       [ 0.09792581],
       [ 0.11916242],
       [ 0.13742635],
       [ 0.19302227],
       [ 0.14129333]], dtype=float32),
array([0.04030978], dtype=float32)]
```

โดยในแอเรย์ชุดแรกคือค่าน้ำหนัก $w^{<t_0>}, w^{<t_1>}, \ldots, w^{<t_{19}>}$ ส่วนค่าสุดท้ายที่มีค่าเดียวคือค่าเอนเอียง b ดังนั้นเอาต์พุตของโมเดลเขียนได้อยู่ในรูป

$$\hat{y} = w^{<t_0>}x^{<t_0>} + w^{<t_1>}x^{<t_1>} + \ldots + w^{<t_{19}>}x^{<t_{19}>} \quad (A.5)$$

ใช้ข้อมูลตรวจสอบเพื่อดูผลการพยากรณ์จากโมเดลที่ผ่านการฝึก ได้ผลดังแสดงในรูปที่ A.22

```
forecast = []
for t in range(len(sample_series) - window_size):
    forecast.append(model.predict(sample_series[t:t +
                    window_size][np.newaxis],verbose=0))
forecast = forecast[split_time-window_size:]
results = np.array(forecast)[:, 0, 0]

plt.figure(figsize=(8, 5))
plot_series(time_valid, x_valid)
plot_series(time_valid, results)
```

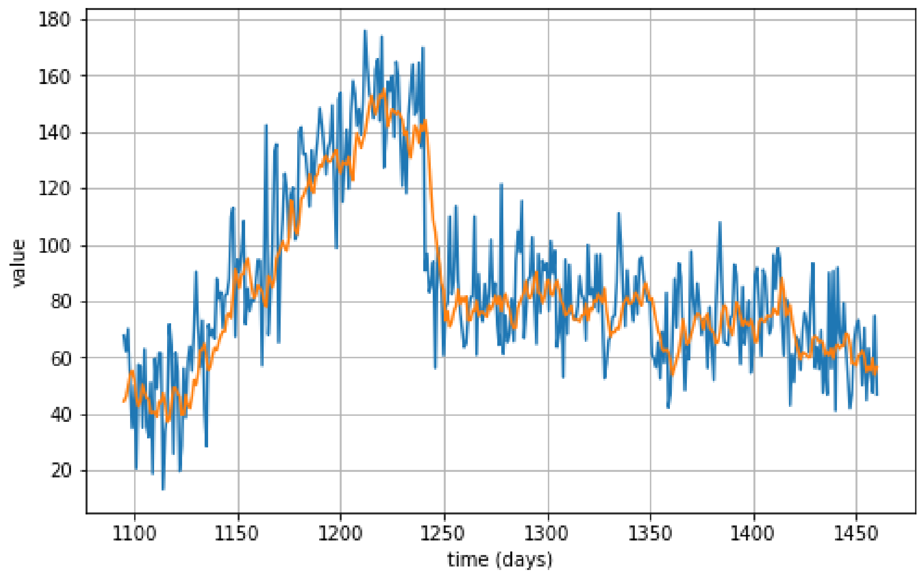

รูปที่ A.22 ผลจากการพยากรณ์โดยโมเดลถดถอยเชิงเส้น

ถึงแม้ว่าการเปรียบเทียบกราฟด้วยตาอาจดูด้อยกว่าวิธีเส้นฐาน แต่เมื่อเปรียบเทียบค่าผิดพลาดจากการพยากรณ์ (วิธีการอย่างง่ายได้ค่า mse=489.2406782463387, mae=17.498463190037835) พบว่าได้ค่าน้อยลง แสดงว่าการพยากรณ์โดยโมเดลชั้นเดี่ยวให้ผลที่ดีกว่า

```
print(keras.metrics.mean_squared_error(x_valid,
results).numpy())
print(keras.metrics.mean_absolute_error(x_valid,
results).numpy())
```

```
306.416
14.010728
```

ตัวอย่าง A.4

ในตัวอย่างนี้จะใช้โมเดล DNN 3 ชั้นที่มีจำนวนเซลล์ในชั้นแฝง 10,10,1 ในการพยากรณ์ข้อมูลเดิมจากตัวอย่างที่ผ่านมา การจัดรูปข้อมูลจะไม่มีอะไรแตกต่างกัน ดังนั้นจะเริ่มโค้ดตรงส่วนการสร้างโมเดล คอมไพล์และฝึกเป็นจำนวน 100 รอบเท่ากัน

```
dnn_model = tf.keras.models.Sequential([
    tf.keras.layers.Dense(10, input_shape=[window_size],
                                activation="relu"),
    tf.keras.layers.Dense(10, activation="relu"),
    tf.keras.layers.Dense(1)
])
```

```
dnn_model.compile(loss="mse", optimizer=
                  tf.keras.optimizers.SGD(
                  learning_rate=1e-6, momentum=0.9))
```

```
history=dnn_model.fit(train_dataset,epochs=100,
                                   verbose=0)
```

พล็อตค่าสูญเสียจากข้อมูลฝึกได้ดังในรูปที่ A.23

```
loss = history.history['loss']
epochs = range(len(loss))
plt.plot(epochs, loss, 'b')
plt.xlabel("Epochs")
plt.ylabel("Loss")
plt.show()
```

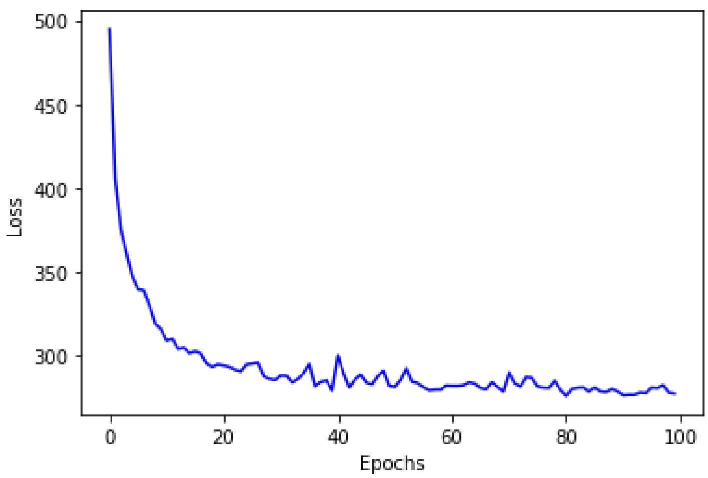

รูปที่ A.23 ค่าสูญเสียระหว่างการฝึก

ใช้ข้อมูลตรวจสอบเพื่อดูผลการพยากรณ์จากโมเดลที่ผ่านการฝึก ได้ผลดังแสดงในรูปที่ A.24

```
dnn_forecast = []
for t in range(len(sample_series) - window_size):
    dnn_forecast.append(dnn_model.predict(
                sample_series[t:t + window_size]
                        [np.newaxis],verbose=0))
dnn_forecast = dnn_forecast[split_time-window_size:]
dnn_results = np.array(dnn_forecast)[:, 0, 0]
plt.figure(figsize=(8, 5))
plot_series(time_valid, x_valid)
plot_series(time_valid, dnn_results)
```

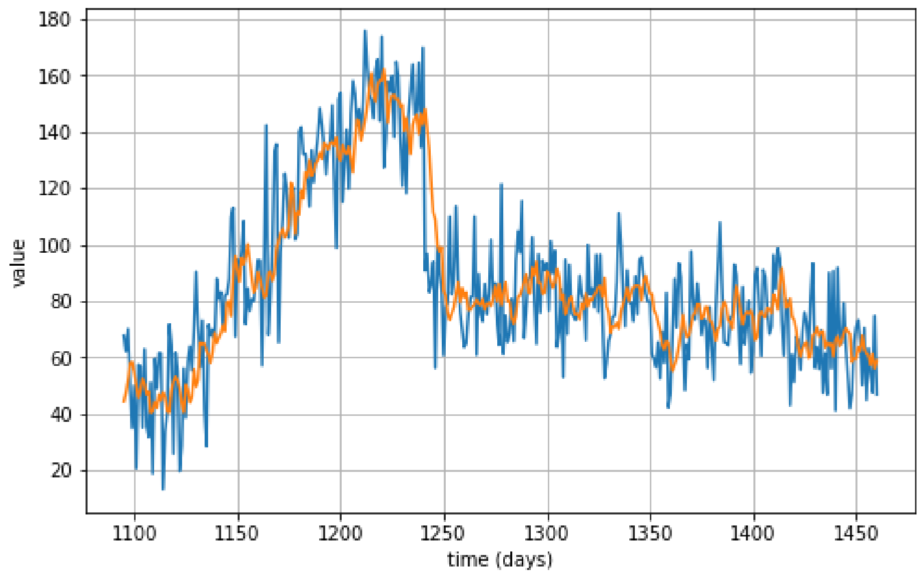

รูปที่ A.24 ผลจากการพยากรณ์โดยโมเดล DNN

ตรวจสอบค่าผิดพลาดจากการพยากรณ์ พบว่ามีค่าน้อยลงกว่าโมเดลถดถอยเชิงเส้น

```
print(keras.metrics.mean_squared_error(x_valid,
                                       dnn_results).numpy())
print(keras.metrics.mean_absolute_error(x_valid,
                                        dnn_results).numpy())
```

```
298.7249
13.627929
```